

제 5회 대구 빅데이터 분석 경진대회

기업 현황분석을 통한 전략적 기업 대출 서비스 제안

Team : 연진시



목차

01. 분석 배경

- 배경 및 필요성
- 분석 목적

02. 분석 개요

- 분석 프로세스
- 활용 데이터 및 전처리

03. 데이터 분석 & 결과

- 카드 데이터 분석
- 주성분 분석과 요인 분석
- 랜덤 포레스트 회귀 분석

04. 활용방안

- 활용 방안 및 시사점




01. 분석 배경

IT/SW산업의 발전

글로벌 경제 침체 속에서도 성장률이 세계 경제 성장률을 상회하고 있는 IT/SW산업은 빠르게 성장하고 있습니다.

코로나 19의 영향으로 금리, 대출이 증가했지만 대출은 특정 서비스업에 집중되어 자금 배분 효율성이 저조합니다.

경제 침체 속에서도 높은 성장률



정부의 재정지원정책 대출 공급 증가



금리 & 대출 공급 증가

but...

자금 배분 효율성



특정 산업에 집중된 대출

01.

분석 배경

■ 디지털 경제로의 전환

디지털 기반 비즈니스는 산업에서 중요한 경영 요소로 자리 잡고 있으며 디지털 경제에 맞는 수익 모델 개발이 매우 중요한 발전 동력이 될 것입니다.

글로벌 플랫폼경제의 부상: 혁신론과 독점론을 넘어서


• • •

DBpia 디지털 혁신에 따른 금융부문 패러다임 전환 가능성



디지털 기반 비즈니스,
새로운 수익 모델 개발의 중요성

02. 분석 개요 - 분석 프로세스



02. 분석 개요 - 활용 데이터 및 전처리

• 활용 데이터


데이터명	기간	활용 변수	출처
IT/SW기업 생태계 실태조사 데이터	2017-2020	업체명, 사업자등록번호, 소재지(시도), 총 매출[2017년~2019년], 연구개발비 투자금액[2017년~2019년], 총 매출 중 IT/SW 분야 매출 비중, 2019년 인력 구성[연구 개발], 2019년 인력 구성[SW개발(제외)], SW융합 기술 분야별 예상 시장전망 [빅데이터~무인이동체(드론 등)]	지역SW산업발전 협의회
대구경북 ITSW 기업 데이터	2009-2022	업체명, 설립일자, 사업자등록번호, 업종명10차_ 세세분류, 업종코드10차_세세분류, 매출액_2017~2019, 기업부설연구소유무, 연구개발전담부서유무, 특허등록건수, 특허출원건수	한국평가데이터
현대카드 데이터	2017-2018	업종명, n시 현대카드매출	SK텔레콤
대구BC카드 데이터	2019-2021	승인월, 가맹점업종, 승인금액	대구은행
금리 (아시아)	2017-2021	대한민국 시장금리	KOSIS

• 데이터 전처리


- 현대카드 & 대구BC카드 데이터
 - 가맹점 업종 : IT/SW산업 vs
관광/여가/숙박 산업으로 필터링
 - 월별 매출액 증감률 계산
- ITSW 기업 데이터 & 실태조사 데이터
-> 최종 활용 데이터 프레임
 - 범주형/논리형 변수 변환
 - 결측값 대치 : 2개의 데이터프레임 매칭
MissForest 방법 사용
- 파생변수 생성
 - 변수들을 이용한 파생변수 생성
 - 매출액 대비 연구개발비 투자금액의 증감률 계산

03. 데이터 분석 & 결과 - 카드 데이터 분석

IT산업 vs 비IT산업 (관광/여가)
평균 매출액 증감률 비교



한국 산업 평균 매출액 증감률보다
높은 경우의 업종코드 추출



03. 데이터 분석 & 결과 -

최종 데이터 프레임 및
파생변수 분포


모든 데이터의 전처리 & 결측값 대치
= 최종 데이터 프레임

	총매 itsw비 중	인력_연 구개발 19	인력 _sw개 발제외 19	기업부 설연구 소유무	연구개 발전담 부서유 무	특허등 록건수	특허출 원건수	업체 명	업종코드10 차_세분 류	대 분 류	...	y	m_1	m_2	m_3	m_4	m_5	m_6	m_7	m_8	m_9
0	82.0	3.79	4.81	0.0	1.0	3.0	4.0	데이 타뱅크	J58222	J ...	0.000312	3.61	4.5	4.32	3.91	3.93	4.29	4.2	4.03	4.06	
1	100.0	2.00	0.00	1.0	0.0	0.0	1.0	지엘 테크21	J58222	J ...	0.006681	4.00	4.0	4.00	4.00	4.00	4.00	4.0	4.00	3.00	
2	80.0	10.00	5.00	1.0	0.0	26.0	32.0	이지 스	J58222	J ...	-0.000517	5.00	5.0	5.00	4.00	4.00	4.00	5.0	3.00	4.00	
3	100.0	1.00	0.00	0.0	0.0	0.0	0.0	지주 소프트	J62090	J ...	-0.048046	5.00	5.0	5.00	4.00	5.00	5.00	4.0	3.00	5.00	
4	100.0	1.00	0.00	0.0	0.0	1.0	4.0	대영 인포텍	J58221	J ...	-0.000591	5.00	5.0	5.00	4.00	4.00	5.00	3.0	3.00	4.00	

매출액 대비 연구개발비 투자금액
분포와 상위 25% 기업

요약 통계량	
mean	-0.089673
std	0.957020
min	-14.949899
25%	-0.008530
50%	0.000299
75%	0.004860
max	1.894993

[표 4] 파생 변수 y의
요약 통계량




[그림 5] 파생변수 y의
상자그림

업체명
지엘테크21
타이거소프트
두손씨엔에이
올인원에듀테크
디케이브릿지웍스
...
생각의 탄생
먹깨비
어썸나인
동우크린
신세계피알

[표 5] y값이
상위 25% 이상인 기업

03. 데이터 분석 & 결과 - 주성분 분석

주성분 갯수가 3개 이상인 경우
주성분의 누적기여율 85% 이상 확보



	설명가능한 분산 비율(고윳값)	기여율	누적 기여율
pca1	243.178480	0.637510	0.637510
pca2	76.663049	0.200978	0.838487
pca3	42.974105	0.112660	0.951147
pca4	7.182599	0.018830	0.969976
pca5	4.881704	0.012798	0.982774
pca6	2.879941	0.007550	0.990324
pca7	2.226470	0.005837	0.996161
pca8	0.504864	0.001324	0.997485
pca9	0.249765	0.000655	0.998139
pca10	0.191093	0.000501	0.998640
pca11	0.134487	0.000353	0.998993
pca12	0.084972	0.000223	0.999216
pca13	0.074220	0.000195	0.999410
pca14	0.066853	0.000175	0.999585
pca15	0.048279	0.000127	0.999712
pca16	0.046894	0.000123	0.999835
pca17	0.035415	0.000093	0.999928
pca18	0.027561	0.000072	1.000000

활용 변수
총 매출 중 IT/SW분야 매출 비중
2019년 인력 구성 [연구 개발]
2019년 인력 구성 [SW개발(제외)]
기업부설연구소유무
연구개발전담부서유무
특허등록건수
특허출원건수
매출액의 2017~2018년 변화율
매출액의 2018~2019년 변화율
SW 융합 기술 분야별 예상 시장전망[빅데이터]
...
SW 융합 기술 분야별 예상 시장전망[무인이동체(드론 등)]

03. 데이터 분석 & 결과 - 적합성 검정

활용 데이터의 적합성 검정

Q. 요인 분석 모델로 사용이 가능한가?

→ Bartlet test : p-value = 0.0


Q. 요인 분석에 활용될 데이터의 변수가 적절하게 설정 되었는가?

→ KMO test : 0.6657 ...

요인 개수의 적합성 검정


고유값(eigenvalue) 기반의 카이저 기준 활용

eigenvalues	
factor1	3.693189
factor2	2.530821
factor3	1.909850
factor4	1.613230
factor5	1.202580
factor6	1.092908
factor7	1.038685
factor8	0.999871



03.

데이터 분석 & 결과 - 요인 분석



요인(feature) 변수에 대한
요인 적재량

요인별 SS loadings, 분산,
누적 분산 분석 결과,
요인 1~5가 전체 분산의
52.71%를 설명함

	feature1	feature2	feature3	feature4	feature5	feature6
SS Loadings	2.400616	2.121364	2.116102	1.537347	1.312796	1.062584
Proportion Var	0.133368	0.117854	0.117561	0.085408	0.072933	0.059032
Cumulative Var	0.133368	0.251221	0.368782	0.454191	0.527124	0.586156


03. 데이터 분석 & 결과 - 요인 분석

요인 분석 결과로 생성한 요인(feature)		
feature 1	특허 관련	특허등록건수, 특허출원건수의 평균(파생변수)
feature 2	데이터 관련 산업	SW융합 기술 분야별 예상 시장 전망 [빅데이터, 인공지능(AI), IoT]의 평균(파생변수)
feature 3	기기 및 차량 관련 산업	SW융합 기술 분야별 예상 시장 전망 [자율주행차, 무인이동체]의 평균(파생변수)
feature 4	연구소	기업부설연구소유무
feature 5	의료 관련 산업	SW융합 기술 분야별 예상 시장 전망 [바이오·헬스]

03.

데이터 분석 & 결과

- 랜덤 포레스트 회귀분석




회귀 분석 결과

n_estimators = 10, max_features = 2, max_depth = 30, RMSE = 0.0269

n_estimators	max_features	max_depth	RMSE
10	2	10	0.0292
10	2	30	0.0269
...	...	...	...
1000	5	50	0.0306

04.

활용방안
및 시사점



제 5회 대구 빅데이터 분석 경진대회

경청해 주셔서 감사합니다

Team : 연진시

참조: Minitab® 20지원, '주성분 분석과 인자 분석 간의 차이'
소프트웨어정책연구소, 김준연, '글로벌 플랫폼경제의 부상 : 혁신론과 독점론을 넘어서(2021.12)'
한국은행 대구경북본부, '대구경북지역 예금은행의 기업대출 특징 및 산업별 자금 배분평가(2022.08)'